

復旦大學

本科毕业论文



论文题目：基于 VAEP 框架改进的足球运动员动作价值评估模型

目录

摘要	3
Abstract	4
1 引言	5
1.1 研究背景与意义	5
1.2 文献综述	5
1.3 研究主要贡献	6
1.4 论文结构安排	6
2 研究框架	8
2.1 数据介绍	8
2.1.1 事件数据 (event stream data)	8
2.1.2 追踪数据 (optical tracking data)	8
2.2 SPADL 球员动作表示方式介绍	8
2.2.1 (non-Atomic) SPADL	9
2.2.2 Atomic SPADL	9
2.3 VAEP 框架介绍	10
2.4 理论模型	10
2.4.1 构建特征	11
2.4.2 构建标签	13
2.4.3 模型选择	14
3 描述性统计	16
3.1 数据集介绍	16
3.2 分类变量探究	16
3.3 时间因素探究	17
3.4 进球因素探究	18
4 实验分析	20
4.1 模型拟合	20
4.2 模型评估	20
4.2.1 标准化 Brier score	20
4.2.2 模型校准	21
4.2.3 模型稳定性	23
4.3 模型解读	25
4.3.1 变量重要性	25
4.3.2 比赛案例分析	27
5 应用分析	34
5.1 球员整体 VAEP 得分排名分析	34
5.1.1 西甲联赛球员排名分析	34
5.1.2 英超联赛球员排名分析	35
5.1.3 球员动作数量-质量关系分析	35
5.2 球员区分动作类型 VAEP 得分排名分析	37
5.3 球员比赛风格对比分析	39
5.3.1 寻找最类似梅西的球员	39
5.3.2 拜仁慕尼黑中后卫对比分析	41
5.3.3 寻找拉姆的替代者	42

6 总结与展望	44
7 附录	45
7.1 (non-Atomic) SPADL 包含的所有动作类型列举	45
7.2 Atomic SPADL 新增的动作类型列举	45
8 参考文献	47

摘要

在如今大数据时代的背景之下，足球数据分析随着足球事件数据的普及也开始不断发展。而在这一领域中，如何去评估足球运动员在场上每一次动作的价值是一个核心的问题。本文基于 Atomic SPADL 这种标准化的球员动作表示方式，结合 VAEP 框架并对其进行标签设计方面的改进，提出了改进后的足球运动员动作价值评估模型，并使用了 Statsbomb 公开提供的 2015/2016 赛季五大联赛全部的事件数据进行模型拟合。通过对拟合模型进行模型评估，可以得出结论：改进后模型在标准化 Brier score、模型校准和模型稳定性这三方面体现出了模型的有效性以及相对原模型的优势；并在对球员动作的具体赋分逻辑上具有合理性。最后在实际应用方面，本文基于改进后的拟合模型计算得出了球员总体和区分动作类型的 VAEP 得分，并分别对这两者进行了球员贡献排名分析；同时，也通过使用区分动作类型的 VAEP 得分，对不同球员之间比赛风格和能力的差异进行了对比分析，并基于此对球队的引援提出了模型角度的建议。

关键词：足球数据分析；动作价值评估；概率预测模型

Abstract

In the era of big data, football data analysis has also been developing alongside the increasing availability of event stream data. A core issue in this field is how to value each action performed by a football player. Based on the standardized action representation method Atomic SPADL, this paper proposes an improved player action valuation model of the VAEP (Valuing Actions by Estimating Probabilities) framework, by introducing new solutions on label design. The improved model is then trained using the full set of event data from the 2015/2016 top five European leagues, publicly provided by Statsbomb. Model evaluation shows that the improved version demonstrates effectiveness and advantages over the original model in terms of standardized Brier score, model calibration, as well as model stability. For practical application, the improved model is used to get both overall and action-type-specific VAEP scores for players, which is intended for further analysis on player contribution rankings. Meanwhile, by utilizing action-type-specific VAEP scores, this study also compares differences in playing styles and abilities across players, with providing model-based recommendations for player recruitment strategies accordingly.

Keywords: Football Data Analysis; Valuing Actions; Probabilistic Model

1 引言

1.1 研究背景与意义

在体育数据分析领域，魔球理论（Moneyball）是最广为人知的故事：预算有限的奥克兰运动家棒球队在球队经理比利·宾恩的带领下，通过数学建模的方式招募低身价的潜在明星，从而一路高歌猛进，在 2002 赛季创下了 20 连胜的惊人纪录，成为了当赛季美国职业棒球大联盟（MLB）中胜利场次最多的球队。

相较于从 19 世纪就开始进行系统化数据收集的棒球，其他运动的数据收集工作更加困难；但随着科技的进步和对数据的愈发重视，诸如网球、篮球和足球等领域的数据分析也开始不断发展。其中，足球数据分析由于场上球员数量多、得分频率低、以及战术变化复杂等因素，整体发展的时间最短。^[1]

魔球理论的核心是在于：希望通过数据，发掘那些可以对球队带来较大贡献、但在传统表现分析中并不突出的球员。类似的，在足球中，如何客观地去衡量一个球员在场上的实际贡献，是足球数据分析的一个核心问题。现如今，随着精细化足球数据的逐步引入，使用算法定量地去解决这个问题逐渐变得可能。而针对这个问题的解决方法的合理性和有效性，也会对各家俱乐部的球员评价体系和球探招募体系产生极其重要的影响。

1.2 文献综述

目前，足球业界以及球迷们最常用且熟知的球员贡献评价指标是由统计学家 Vic Barnett, Sarah Hilditch (1993)^[2]提出的预期进球（xG）这一概念，并在后来由 Jake Ensum, Richard Pollard, Samuel Taylor (2004)^[3]和 Sander Itjisma (2011)^[4]等人分别提出了不同的模型构建的具体方法。顾名思义，预期进球（xG）就是进球的概率，本质上衡量的是得分机会的质量；基于这一指标，我们就可以通过对比每个球员获得的预期进球和他实际创造的进球数量，来判断该球员把握射门机会能力的强弱。由预期进球衍生出来的还有 Tom Worville (2017)^[5]提出的预期助攻（xA）等想法类似的概率指标。但实际上，射门或助攻对于足球比赛来说其实只是相当一小部分的组成事件，如果只关注这类事件的话就会遗漏掉一场比赛中绝大部分的信息。同时，前场球员天然在这些与进攻相关的指标上表现更好，如果用这些指标一起来评价前场和后场球员的话，得到的结果会非常的不公平，所以这些指标大多也只能用于进攻球员的评价中。

于是在 2020 年前后，有许多的学者提出了衡量所有动作（除射门外，还包括传球、盘带、解围、抢断等动作）贡献值的模型，其中比较常用的主要有 Tom Decroos, Lotte Bransen, Jan Van Haaren, Jesse Davis (2019)^[6]提出的 VAEP 模

型、以及 Karin Singh (2019) [7] 提出的 xT 模型这两种。xT 模型的想法是：先将整个足球场划分为若干个小区域，然后通过马尔科夫链的方法得出每个小区域最终能够形成进球的概率（即 xT），并通过计算每个球员行动前后区域的 xT 之差来评估其贡献。但这一方法只考虑了位置移动的因素，并没有考虑具体的动作类型以及这一移动的结果和影响。[8]

VAEP 模型则是目前评价球员动作价值的方法中普适性最强、应用性最好、也是相对最完善的一个。它充分利用了事件数据（参考下文的介绍）中的各种细节（包括位置、时间、事件类型等），并使用了机器学习算法拟合模型来得出每个动作的贡献值。同时，也有相关学者利用 VAEP 模型的框架进行了进一步的研究，将其应用于解决足球实战中的一些实际问题，如 Pieter Robberechts (2020) [9] 提出的 VPEP 模型单独对于逼抢行为的价值进行了建模。

以上所述的这些模型，基本都是由国外学者提出的。在足球数据分析这一领域，国内的研究起步较晚，目前的应用也较为落后。但随着近些年国内的一些数据服务商开始与国际知名的数据公司（如 Opta）进行合作，他们也开始逐渐建立起了自己相应的数据体系；也相信未来在这一方面的研究将会有长足的发展。

1.3 研究主要贡献

本文的研究方向主要是针对 VAEP 框架进行改进。对于下文里提到的 VAEP 框架针对每一比赛状态拟合的进球概率模型 P_{scores} ，我们发现，在目前的标签构建方法下， P_{scores} 模型对于每次射门对应的比赛状态估计的进球概率普遍不准，反映为经常大幅偏离预期进球模型计算出来的 xG 值。考虑到预期进球模型是目前足球数据分析领域公认的最成熟的模型，我们可以近似地认为其计算得出的 xG 值是准确的；因此我们希望对于每次射门对应的比赛状态，VAEP 框架拟合的进球概率模型 P_{scores} 能够尽量和预期进球模型的计算结果保持一致。基于这一想法，我们借用了预期进球模型的结果，对 VAEP 框架的标签设计进行了改进，以期得到更加准确的球员动作价值评估结果。

1.4 论文结构安排

本文的结构安排如下：

- 1、在第二部分，我们将首先对研究使用的数据、目前的 VAEP 模型所使用的具体框架、以及我们如何改进这一体系进行详细的介绍；
- 2、在第三部分，我们将进行描述性统计，希望基于我们使用的数据集，对足球比赛在数据上的表现得到一个初步的量化认识；

3、在第四部分，我们将完成改进后模型的拟合，将其与改进前的 VAE_P 模型进行对比以完成模型评估，并对改进后模型进行解读以获取对其的直观认识；

4、在第五部分，我们最后将尝试应用我们的模型，去分析足球业界中的实际问题，主要包括球员排名和球队引援这两方面。

2 研究框架

2.1 数据介绍

目前，足球业内主要使用以下两种数据进行数据科学相关分析。

2.1.1 事件数据 (event stream data)

事件数据标注了比赛中每个事件（如传球、射门、红黄牌、比赛开始结束、换人等）发生的时间、位置和成功与否等信息。多家公司（如 StatsBomb、Wyscout 和 Opta）都在通过人工标注的方式生成这类数据。因为生成事件数据的成本相对不高，这些公司都公开提供了一部分主流联赛的示例数据集供相关人员进行研究，这也使得事件数据是目前在评估球员贡献方面主要应用的数据类型。

事件数据虽然应用广泛，但也存在着一些问题：人工标注导致此类数据的可靠性有时无法得到很好的保证；且它忽略了无球队员的状态，从而丢失了场上整体局势的信息；同时，不同数据供应商对于事件的记录方式不同，数据格式兼容性复杂，从而增加了标准化数据分析的难度。

2.1.2 追踪数据 (optical tracking data)

追踪数据以每秒几十次的频率记录场上每个球员以及球所在的位置，从而较为完整地刻画了场上每一帧的局势，是事件数据的一个良好的补充。但这一基于计算机视觉的自动识别技术相对较为复杂，成本也相对高昂，所以跟踪数据仅在少数一些财力雄厚的联赛或俱乐部中被使用，市面上也几乎没有公开的可供研究的数据集。目前应用追踪数据来评估球员贡献的研究者大多都是受雇于知名足球俱乐部或相关数据供应商，他们研究所使用的数据集也都是非公开的。因此，本文以下的内容主要还都是基于事件数据展开研究。

2.2 SPADL 球员动作表示方式介绍

SPADL (Soccer Player Action Description Language) 是由比利时鲁汶大学 DTAI 体育分析实验室基于足球专家的意见，提出的一种事件数据的标准化表示方式。它提供了将 Statsbomb, Wyscout 和 Opta 事件数据转化为标准化 SPADL 动作表达方式的接口，从而便于研究者基于这一规范的表达方式进行进一步研究。它的核心在于只包含每一次由球员发生的动作（如射门动作、传球动作等），剔除了所有其他多余的事件（如比赛结束事件等），并用统一的特征集合来表示每次动作。具体来说，SPADL 又分为 (non-Atomic) SPADL 和 Atomic SPADL 这两种表达方式，它们主要的区别在于包含动作种类的不同，以及相应的使用特征集合的不同。

2.2.1 (non-Atomic) SPADL

这是 SPADL 表示方式的初始版本。对于每次动作，它用统一的以下九个特征来进行表示：

- 1、**StartTime**: 动作的开始时间；
- 2、**EndTime**: 动作的结束时间；
- 3、**StartLoc**: 动作开始的位置坐标(x,y)；
- 4、**EndLoc**: 动作结束的位置坐标(x,y)；
- 5、**Player**: 进行该动作的球员；
- 6、**Team**: 该球员所在的球队；
- 7、**ActionType**: 动作类型（一共有 21 种，具体列举见附录 7.1）；
- 8、**BodyPart**: 球员进行该动作所使用的身体部位（包括 foot 脚、head 头和其他）；
- 9、**Result**: 进行该动作的结果（主要是成功和失败两种；对于某些动作还会形成 offside 越位、yellow card 黄牌、red card 红牌和 own goal 乌龙球）。

2.2.2 Atomic SPADL

这是 SPADL 表达方式的改进版本。它的主要想法是，对于足球场上的很多动作来说，它们并不是单独由某一位球员完成的——如每一次成功的传球，实际上可以被视为传球队员传出球和接球队员接到球这两个动作的结合。而只将这一次传球动作记录在传球队员的信息下是不完整的。所以 Atomic SPADL 进行了如下改进，它移除了原先 SPADL 中的 result 特征，并依据以下思想加入了一些新的动作类型：

- 1、如果一次传球成功完成，则会针对接球队员引入一个 **receival** 接球动作；
- 2、如果一次传球被截断，则会针对截球队员引入一个 **interception** 拦截动作；
- 3、如果一次传球出界，则会针对传球队员引入一个出界事件 **out**。

类似的，对于射门和任意球等动作类型，我们也可以分别将其拆分为两次动作（拆分后新增的动作类型见附录 7.2）。在这种表示方式下，我们认为做出的每次动作都是成功的，而具体结果是好是坏，和紧接着发生的下一个动作有关。直觉上，这种改进表示方法的好处在于：它有助于区分发起动作的球员（例如传球球员）和完成动作的球员（例如接球球员）所分别做出的贡献。同时，根据 SPADL 提出者已有的研究成果显示，在 Atomic SPADL 表达方式下构建的动作价值评估模型相比 (non-Atomic) SPADL 具有更好的稳定性。综合考虑到 Atomic SPADL 以上的两点优势，本文后续的研究都将基于 Atomic SPADL 的表达方式框架。

2.3 VAEP 框架介绍

VAEP (Valuing Actions by Estimating Probabilities) 也是由比利时鲁汶大学 DTAI 体育分析实验室提出的, 一种评估球员动作价值的框架。它的想法是, 球员在场上做出的每个动作目的不外乎增加本队进球概率, 或降低本队丢球概率。所以 VAEP 框架希望通过计算球员的某一动作对于本队在目前比赛状态下进球或丢球的概率改变, 来作为对球员动作价值的评估。

该框架定义比赛状态 $S_i = [a_{i-k}, \dots, a_i]$, 其中 a_i 表示比赛中发生的第 i 个动作, 即比赛状态 S_i 可以通过当前动作 a_i 倒推 k 个动作形成的顺序序列来表示。同时, 定义 $P_{\text{scores}}(S_i, x)$ 为球队 x 在比赛状态 S_i 下在短期未来内进球的概率, $P_{\text{concedes}}(S_i, x)$ 为球队 x 在比赛状态 S_i 下在短期未来内丢球的概率, 其中, 短期未来的定义为比赛状态 S_i 后的 m 个动作内。根据此框架提出者已有的研究经验, $k = 2$ 和 $m = 10$ 是最优的超参数选择。

该框架进一步定义动作 a_i 对球队进球方面的贡献为球队在动作 a_i 前后进球概率的变化值, 即:

$$\Delta P_{\text{scores}}(a_i, x) = P_{\text{scores}}(S_i, x) - P_{\text{scores}}(S_{i-1}, x);$$

类似的, 定义动作 a_i 对防止球队丢球方面的贡献为球队在动作 a_i 前后丢球概率变化值的相反数, 即:

$$-\Delta P_{\text{concedes}}(a_i, x) = P_{\text{concedes}}(S_i, x) - P_{\text{concedes}}(S_{i-1}, x)。$$

由此, 就可以定义一个动作最终的贡献值 VAEP value 为该动作在进球方面的贡献和防止丢球方面的贡献的加和, 即:

$$V(a_i, x) = \Delta P_{\text{scores}}(a_i, x) - \Delta P_{\text{concedes}}(a_i, x)。$$

VAEP 框架的优势在于, 它将一个主观的球员动作贡献评估任务转化成了一个可以量化的概率估计任务; 同时并不提前预设动作的表示方式, 使得这一框架具有更高的普适性。

2.4 理论模型

这一部分将介绍本研究借助 Atomic SPADL 的动作表达方式和 VAEP 框架, 对球员动作价值评估模型进行理论构建的具体做法。

根据 VAEP 框架, 其核心在于估计在当前比赛状态 S_i 下, 球队的进球概率 $P_{\text{scores}}(S_i, x)$ 和丢球概率 $P_{\text{concedes}}(S_i, x)$ 。值得注意的是, 由于本队的进球概率即对方的丢球概率, 本队的丢球概率即对方的进球概率, 所以只需要针对每个比赛状态下的控球球队进行概率估计即可。由此, 可以总结这一概率估计问题如下:

已知：比赛状态 S_i ，且 x_i 是比赛状态 S_i 下的控球球队；

估计：球队 x_i 的进球概率 $P_{\text{scores}}(S_i, x_i)$ 和丢球概率 $P_{\text{concedes}}(S_i, x_i)$ 。

针对这一概率估计问题，我们需要构建相应的特征和标签，并选取合适的机器学习分类算法进行建模。在构建特征部分，本文主要是参考已有的设计方法，即比利时鲁汶大学 DTAI 体育分析实验室基于他们提出的以上两大框架，为了解决这一概率估计问题对应提出的特征构建方法；而在构建标签和模型选择部分，本文将尝试在原有的想法上改进标签的设计方法，并基于这一新的标签构建思路选择合适的模型和拟合方法。

2.4.1 构建特征

基于前文所述经验，本文取每个比赛状态 $S_i = [a_{i-2}, a_{i-1}, a_i]$ ，即最近的连续三个动作，并基于这三个动作建立以下三类特征。这一特征构建方法是参考了比利时鲁汶大学 DTAI 体育分析实验室在 VAEP 框架原论文中的特征构建方法。

2.4.1.1 Atomic SPADL 基础特征

对于这三个连续动作中的每一个，可以基于 Atomic SPADL 动作表达方式来构建一组分类特征和连续变量特征，即动作类型和球员进行该动作所使用的身体部位对应的分类特征、动作所在位置的 (x, y) 坐标对应的连续变量特征、以及自比赛开始以来经过时间的连续变量特征。具体列举如下。

表 2.1 Atomic SPADL 基础特征表

变量名称	变量类型	变量解释
actiontype_a0	category	动作 a0 类型
actiontype_a1	category	动作 a1 类型
actiontype_a2	category	动作 a2 类型
bodypart_a0	category	动作 a0 所使用的身体部位
bodypart_a1	category	动作 a1 所使用的身体部位
bodypart_a2	category	动作 a2 所使用的身体部位
x_a0	float	动作 a0 所在位置在 x 轴上的坐标
y_a0	float	动作 a0 所在位置在 y 轴上的坐标
x_a1	float	动作 a1 所在位置在 x 轴上的坐标
y_a1	float	动作 a1 所在位置在 y 轴上的坐标
x_a2	float	动作 a2 所在位置在 x 轴上的坐标
y_a2	float	动作 a2 所在位置在 y 轴上的坐标
time_seconds_overall_a0	float	动作 a0 自比赛开始以来经过的时间

time_seconds_overall_a1	float	动作 a1 自比赛开始以来经过的时间
time_seconds_overall_a2	float	动作 a2 自比赛开始以来经过的时间

2.4.1.2 复合特征

复合特征即融合了单个动作内部信息以及连续动作之间信息的特征。在单个动作内部，这些进一步构建的特征包括：该动作相对对手球门的距离和角度、以及该动作移动的距离和方向。在连续动作之间，这些进一步构建的特征包括：连续动作之间经过的时间、以及球权是否发生了转换。这些特征能给予我们有关当前比赛节奏的信息，具体列举如下。

表 2.2 复合特征表

变量名称	变量类型	变量解释
dist_to_goal_a0	float	动作 a0 相对球门的距离
angle_to_goal_a0	float	动作 a0 相对球门的角度
dist_to_goal_a1	float	动作 a1 相对球门的距离
angle_to_goal_a1	float	动作 a1 相对球门的角度
dist_to_goal_a2	float	动作 a2 相对球门的距离
angle_to_goal_a2	float	动作 a2 相对球门的角度
mov_d_a0	float	动作 a0 移动的距离
mov_angle_a0	float	动作 a0 移动的方向
mov_d_a1	float	动作 a1 移动的距离
mov_angle_a1	float	动作 a1 移动的方向
mov_d_a2	float	动作 a2 移动的距离
mov_angle_a2	float	动作 a2 移动的方向
dx_a0	float	动作 a0 的方向(基于单位向量在 x 轴上的坐标表示)
dy_a0	float	动作 a0 的方向(基于单位向量在 y 轴上的坐标表示)
dx_a1	float	动作 a1 的方向(基于单位向量在 x 轴上的坐标表示)
dy_a1	float	动作 a1 的方向(基于单位向量在 y 轴上的坐标表示)
dx_a2	float	动作 a2 的方向(基于单位向量在 x 轴上的坐标表示)
dy_a2	float	动作 a2 的方向(基于单位向量在 y 轴上的坐标表示)
time_delta_1	float	动作 a0 和 a1 之间经过的时间
time_delta_2	float	动作 a0 和 a2 之间经过的时间
team_1	bool	动作 a0 和 a1 对应的球员是否同队
team_2	bool	动作 a0 和 a2 对应的球员是否同队

2.4.1.3 比赛情境特征

比赛情境特征包括在动作 a_i 之后控球球队在比赛中已进的球数、已丢的球数、以及两队的进球差。这些特征能够从侧面反映出球队目前的比赛风格（如 1-0 领先的球队通常会比 0-1 落后的球队踢得更保守），具体列举如下。

表 2.3 比赛情境特征表

变量名称	变量类型	变量解释
goalscore_team	int	动作 a_0 后控球球队在比赛中已进的球数
goalscore_opponent	int	动作 a_0 后控球球队在比赛中已丢的球数
goalscore_diff	int	动作 a_0 后两队的进球差

2.4.2 构建标签

在 VAEF 框架的原论文中，构建标签的方式相对较为简单。对于 $P_{\text{scores}}(S_i, x_i)$ 对应的分类器，若控球球队在动作 a_i 之后的 m 个动作中进球，就给比赛状态 S_i 分配正标签（= 1），并在其他所有情况下分配负标签（= 0）；类似地，对于 $P_{\text{concedes}}(S_i, x_i)$ 对应的分类器，若控球球队在动作 a_i 之后的 m 个动作中丢球，就给比赛状态 S_i 分配正标签（= 1），并在其他所有情况下分配负标签（= 0）。基于前文所述经验， $m = 10$ 是最优的超参数选择。

在本文中，我们将尝试对这一标签的构建方式进行改进。原先的标签构建方式固然直观易懂，但这也导致了标注为正标签（= 1）的样本数量极其稀少，因为进丢球在足球比赛中是极其稀疏的事件。在 Atomic SPADL 的表达方式下，一场比赛平均有 3000 个左右的状态，但平均只会形成 3 个左右的进球。在原先的标签构建方式下，纵使选择了超参数 $m = 10$ ，平均而言，依然只有 1% 左右的样本会分配到正标签（= 1），从而不可避免的形成了一个极度不平衡的二元数据集。

同时，只根据进丢球与否来构建标签，还会导致丢失掉很多比赛进行过程中的信息。比如，对于一次很好的进攻机会，某位前锋已经获得了面对空门、且没有压力的射门机会，但他却将球射偏了。在原先的标签构建方式下，和这次进攻相关的比赛状态都会被分配到负标签（= 0），因为最终并没有形成进球。但实际上，这次进攻没有造成进球的主要责任应该都落在那位前锋身上，而之前组织进攻的球员都应该因为这次绝佳的机会得到表现加分。

所以我们希望改进原先的标签构建方式，不只是基于进丢球这种稀疏且偶然性大的事件来构建标签。对此，我们的想法是，将每次射门动作也纳入标签构建

的考虑范畴之中。一方面，射门动作相比进丢球事件发生的频率显著更高——一场比赛平均而言会有 20 次左右的射门，远高于 3 次左右的进球；另一方面，事件数据供应商（如 StatsBomb、Wyscout 和 Opta）对于每次射门事件都会提供对应的预期进球值（xG），相比进球与否的 01 二元结果标签，预期进球是刻画每次以射门为终结的进攻机会质量的更好方式。

由此，我们提出改进后的标签构建方式：

1、对于 $P_{\text{scores}}(S_i, x_i)$ 对应的分类器：

若动作 a_i 是进球事件 goal，则给比赛状态 S_i 分配正标签（= 1）；

若控球球队在动作 a_i 之后的 m 个动作中射门，则给比赛状态 S_i 分配该射门对应的连续值 xG 标签（0-1 之间）；

并在其他所有情况下分配负标签（= 0）。

2、对于 $P_{\text{concedes}}(S_i, x_i)$ 对应的分类器：

若动作 a_i 是乌龙球事件 owngoal，则给比赛状态 S_i 分配正标签（= 1）；

若控球球队在动作 a_i 之后的 m 个动作中被射门，则给比赛状态 S_i 分配该射门对应的连续值 xG 标签（0-1 之间）；

并在其他所有情况下分配负标签（= 0）。

在以上的新标签构建方式下，如果出现某位前锋因为其个人原因而错失绝佳良机的情况，我们就可以根据创造出的射门机会对应的预期进球 xG，对之前组织进攻的球员进行表现加分，而对于错失良机的前锋进行表现扣分。相对于原先的标签构建方式，我们的新标签构建方式在分配动作价值方面更加合理。直观上，我们的新标签构建方式就是希望在 01 二元进丢球结果标签之外，在比赛的发展过程中，给予模型更多的关于当前比赛状态下进丢球概率的补充信息，而每次射门对应的预期进球 xG 则是目前唯一成熟且可获得的此类信息。

2.4.3 模型选择

相较于原先的标签构建方式，我们提出的新标签构建方式对模型提出了更高的要求，因为在这一新的标签构建方式下，除了 01 二元标签外，还包含了大量取值在 0-1 之间的连续值 xG 标签，而这对于大多数分类模型来说都无法直接兼容。对此我们采取的方法是：对于每一个标签为连续值 xG 的样本，我们都将其人工复制为两个样本，分别对其分配正负标签，并对应赋予它们 (xG, 1 - xG) 的权重；而对于所有其他样本，则都赋予 1 的权重。这样我们就可以将数据转化为加权 01 二元样本，从而也就能适配大部分的分类模型。

理论上，所有适配加权 01 二元样本、且能预测概率值的分类模型都可被使用（如逻辑回归、随机森林等）。但考虑到数据中包含了大量的分类特征（主要是动作类型 ActionType），我们最终选择的模型要对分类特征有较好的适配度；

Catboost 在这方面有较大优势，它针对分类特征天然的处理能力能减少繁琐的预处理步骤。所以，本文后续的实验部分都将应用 Catboost 算法进行模型拟合。^[11]

3 描述性统计

3.1 数据集介绍

本文使用的数据集是 Statsbomb 提供的 2015/2016 赛季五大联赛（德甲、西甲、法甲、英超、意甲）所有比赛的事件数据。这也是市面上唯一公开的某年份五大联赛全赛季事件数据集。其中，德甲联赛由于只有 34 轮，所以总比赛数少于其他四大联赛；法甲联赛则是缺失了三场比赛的数据，但这一缺失不会对我们的分析产生显著影响。

表 3.1 列出了 2015/2016 赛季五大联赛平均每场比赛的传球数、射门数和进球数。场均传球数方面，法甲联赛最多，西甲联赛最少；场均射门数方面，则是英超、意甲和德甲联赛偏多，西甲和法甲联赛偏少；但西甲联赛却有着仅次于德甲联赛的场均进球数，而意甲联赛的场均进球数却只高于法甲联赛，说明西甲联赛的平均射门转化率较高，而法甲联赛的平均射门转化率较低；德甲联赛的场均进球数最高，这也与大家对德甲联赛大开大合的印象一致。

表 3.1 2015/2016 赛季五大联赛场均数据汇总表

	games_cnt	pass_per_game	shot_per_game	goal_per_game
Bundesliga	306	833.76	24.08	2.74
LaLiga	380	828.89	22.79	2.67
Ligue1	377	860.73	21.92	2.43
PremierLeague	380	844.86	24.78	2.6
SerieA	380	847.65	24.73	2.5

3.2 分类变量探究

根据理论模型构建特征部分，我们所使用的特征中的分类变量主要是动作类型、和动作使用的身体部位这两者。

对于动作类型，从图 3.1 中可以看出，传球、带球、接球是最主要的三大动作类型，占比均超过了 25%；在这之后，是两大防守动作拦截和解围；射门（包括普通射门 shot、任意球射门 shot_freekick 和点球射门 shot_penalty）相对所有动作类型的占比仅有 0.84%，依然是较为稀疏的事件，但相较于进球仅有 0.09% 的占比，将射门加入标签的构建过程已经可以对我们的模型产生很大帮助了。




图 3.1 动作类型频率分布图

而对于动作使用的身体部位，从图 3.2 中可以看出，使用脚部处理球占到了绝大多数的超过 95%；头部处理球仅占到 2.6%；使用其他身体部位处理球的占比是 2.35%。




图 3.2 动作使用的身体部位频率分布图

3.3 时间因素探究

在这一部分，我们尝试初步探究射门和进球在时间上的分布规律。

对于射门，从图 3.3 中可以看出，下半场的射门数量普遍高于上半场比赛。在比赛的开始阶段，两支球队一般都会采取较为保守的试探策略，因而射门数显著较低，在比赛发展了约 5 分钟后才逐渐升高至稳定水平。在比赛 45 分钟后的 2-3 分钟之内形成的射门数高峰主要是由于这一数字叠加了上半场补时阶段的射门数量和下半场开始阶段的射门数量，因而出现虚高；但在比赛 90 分钟左右形成的射门数高峰是实际存在的，这反映出对于在常规时间的尾声阶段依然留有悬念的比赛来说，球队普遍进攻的欲望更高，因为他们会迫切尝试在最后阶段改变比赛结果。而由于每场比赛的补时时间长短不同，在 90 分钟之后的射门数依然会显著降低。




图 3.3 射门时间分布图

而对于进球，从图 3.4 中可以看出，类似的，下半场的进球数量普遍高于上半场比赛。除去比赛 45 分钟后的 2-3 分钟之内由于叠加了上半场补时阶段和下半场开始阶段的进球数量而出现的虚高情况，两个进球数的高峰是在比赛 40 分钟以及 75-85 分钟的时间段。这普遍也是大家认为球员体能容易出现瓶颈的时刻，因为这两个时间段正好是上下半场临近结束的时候，其中下半场由于整场比赛的消耗导致这一瓶颈期会来的更早一些。




图 3.4 进球时间分布图

3.4 进球因素探究

在这一部分，我们简单地探究相对对手球门的距离和角度对一次射门是否形成进球的影响。我们针对所有射门和形成进球的射门，分别画出它们对应的以上两个因素的箱线图。从图 3.5 中可以看出，形成进球的射门平均而言相对对手球门的距离更近，但在相对对手球门的角度上两者没有显著的分布差异。




图 3.5 进球和射门对应的相对对手球门的距离和角度因素箱线图

4 实验分析

4.1 模型拟合

我们首先使用网格搜索调参的方法获得 Catboost 算法在我们的数据集上的最优超参数。由于我们在构建特征时使用了前序连续三个动作的信息，导致样本间并不完全独立，所以不适用普通的随机交叉验证分层。对此，我们选择使用五大联赛的天然划分作为交叉验证的五层，从而可以有效区分开训练集和验证集。

在网格搜索调参的评估指标方面，我们选择使用 Brier score，即：

$$BS = \frac{1}{N} \sum_i^N (p_i - y_i)^2。$$

因为在本研究问题中，我们实际关注的是预测概率值的准确度（即模型校准的好坏），而并不关注样本具体是会被预测为正样本还是负样本。Brier score 当且仅当每个样本的概率值预测误差都被最小化的时候取到最小值，所以是模型校准良好的评估指标。^[12]

我们基于 Brier score 的评估指标，使用网格搜索交叉验证调参分别获得了 P_{scores} 对应的 Catboost 分类器和 P_{concedes} 对应的 Catboost 分类器的最优超参数，具体见表 4.1。

表 4.1 P_{scores} 和 P_{concedes} 对应的 Catboost 分类器的最优超参数表

	n_estimators	learning_rate	max_depth	reg_alpha
P_{scores}	300	0.05	12	0.2
P_{concedes}	100	0.05	15	0.2

最后，我们使用所有五大联赛的数据，并根据以上超参数，分别拟合最终的 P_{scores} 对应的 Catboost 分类器和 P_{concedes} 对应的 Catboost 分类器。

4.2 模型评估

我们将从标准化 Brier score，模型校准和模型稳定性三个角度对得到的模型进行评估。同时，我们也类似地通过以上方法拟合了标签构建方式改进前的模型，并试图在这三个方面对改进前后的模型进行对比分析。

4.2.1 标准化 Brier score

由于数据可获取度方面的限制，我们无法得到 2015/2016 赛季之后五大联赛的全赛季数据，也就无法在单独的测试集上计算 Brier score。对此，我们选择使

用模型拟合过程中交叉验证的平均 Brier score 得分作为替代指标进行分析。

需要注意的是，Brier score 是一个绝对值指标，所以一个具体的 Brier score 是坏是原和原标签的分布高度相关(比如，0.1 的 Brier score 在一个正负标签 50/50 分布的样本中可以反映出模型效果优秀，但在一个正负标签 99/1 分布的样本中却可能反映出模型表现很差)。而由于我们改进前后的模型的标签构建方式不一致，自然也就无法进行 Brier score 的直接对比。

对此，一个可行的解决方法是使用标准化的 Brier score。我们可以计算用所有样本标签的均值作为所有样本预测概率值得到的 Brier score 并将其作为基准，然后用模型得到的 Brier score 与其进行对比，就可以得到标准化的 Brier score (Normalized Brier score)，即：

$$NBS = BS/BS_{baseline}。$$

我们希望我们的模型的 Brier score 至少要好于基准值，即标准化 Brier score 至少要小于 1。

我们分别对标签改进前后， P_{scores} 对应的模型和 $P_{concedes}$ 对应的模型计算了他们的标准化 Brier score，结果见表 4.2。可以看出，改进前后模型在标准化 Brier score 上的表现差别不大，改进后的 P_{scores} 模型相比改进前的标准化 Brier score 略有升高，而改进前后 $P_{concedes}$ 模型的标准化 Brier score 几乎不变，且这四个值都小于 1。可以认为，改进前后的模型都在标准化 Brier score 的评估准则上有着不错的效果。

表 4.2 模型改进前后 P_{scores} 和 $P_{concedes}$ 的标准化 Brier score 表

	改进前	改进后	改进前	改进后
	P_{scores}	P_{scores}	$P_{concedes}$	$P_{concedes}$
标准化 Brier score	0.810	0.831	0.873	0.871

4.2.2 模型校准

在本文的研究问题中，我们关注的模型评估核心是预测概率值的准确度，也即模型校准的好坏。Brier score 是一个总体的概括性指标，但它并不能对具体样本的校准好坏给出评价。同时，模型校准的参考标签在我们的研究问题中也非常难以获得，因为对于大部分比赛状态来说，都很难定量地给出其对应的 P_{scores} 和 $P_{concedes}$ 参考值。我们现在唯一能获得的、且被广泛认可的校准参考标签，是每次射门的预期进球 (xG)，它对应每次射门对应的比赛状态的 P_{scores} 。这也是我们改进标签构建方法的核心。因此，我们希望对比改进前后模型对于每次射门对应比赛状态的 P_{scores} 的校准，来评估分析这两个模型。

我们首先计算了所有射门对应比赛状态的 P_{scores} 预测值和 xG 参考标签值之间的平均绝对误差 (MAE)：改进前模型的 MAE 是 0.077，改进后模型的 MAE 是 0.028，改进后模型的平均绝对误差显著低于改进前模型。

然后，我们又分别对改进前后模型做出了它们射门对应比赛状态的 P_{scores} 校准曲线图。从图 4.1 中可以看出，改进后模型在这一部分比赛状态的模型校准方面确实显著优于改进前模型。改进后模型的校准曲线和完美校准直线的重合度很高，仅在 xG 参考标签值为 0.2 附近的范围内出现了略微的高估，并在 xG 参考标签值大于 0.5 的区域内出现了略微的低估。而改进前模型的校准曲线和完美校准直线的重合度较低，既在 xG 参考标签值小于 0.1 的范围内出现了低估，又在 xG 参考标签值大于 0.1 的区域内出现了越来越严重的高估。由此可以认为，改进后模型在模型校准方面确实有了很大程度的改进，这也反映出我们改进标签构建的想法是合理有效的。




图 4.1 (a) 改进后模型每次射门对应比赛状态的 P_{scores} 校准曲线图




图 4.1 (b) 改进前模型每次射门对应比赛状态的 P_{scores} 校准曲线图

4.2.3 模型稳定性

在拟合了 P_{scores} 和 P_{concedes} 这两个 Catboost 分类器并预测了每个比赛状态对应的 P_{scores} 和 P_{concedes} 概率预测值之后，我们就可以根据研究框架所述的方法计算出对应的每个动作的价值评分 **VAEP value**。我们最终的目标是综合计算出每个球员的动作价值评分，但考虑到每个球员的出场时间并不相同，我们需要拉齐时间的因素来保证我们得到的指标的公平性。我们选择计算每个球员在每 90 分钟之内的 **VAEP value** 总和来作为他的动作价值综合评分，并依据这一评分对球员进行排名。

然后我们就可以开展这一部分关于模型稳定性的讨论。一个很直观的想法是，对任何一个评分系统来说，它对于球员的评分结果在短期内（比如一个赛季内，这也是我们使用数据的周期）应该具有稳定性，因为我们可以近似认为大部分球员的技战术水平在短期内并不会会有明显的变化；只有在更长的周期内，如两到三个赛季以上，每个球员的整体技战术水平才可能出现显著的上升或下降。所以我们考虑如下对评分系统稳定性进行度量的方法：我们随机地将所有样本分为两半，分别用这两半数据得到球员的综合评分，并计算这两列评分的相关系数，从而得

到有关评分系统稳定性的结论。

为了降低数据划分对分析的影响，我们随机尝试了 100 次不同的数据划分方式，并分别计算了每次数据划分方式下两半数据得到的两列评分的 Pearson 和 Spearman 相关系数。改进前模型得到的 Pearson 和 Spearman 相关系数的平均值分别是 0.604 和 0.525，而改进后模型得到的 Pearson 和 Spearman 相关系数的平均值分别是 0.640 和 0.578。同时，我们做出改进前后模型得到的两大相关系数分布的对比图，如图 4.2 所示。可以明显看出，改进后模型的 Pearson 和 Spearman 相关系数都显著高于改进前模型。由此我们可以认为，基于改进后模型得到的评分系统确实具有更高的稳定性。

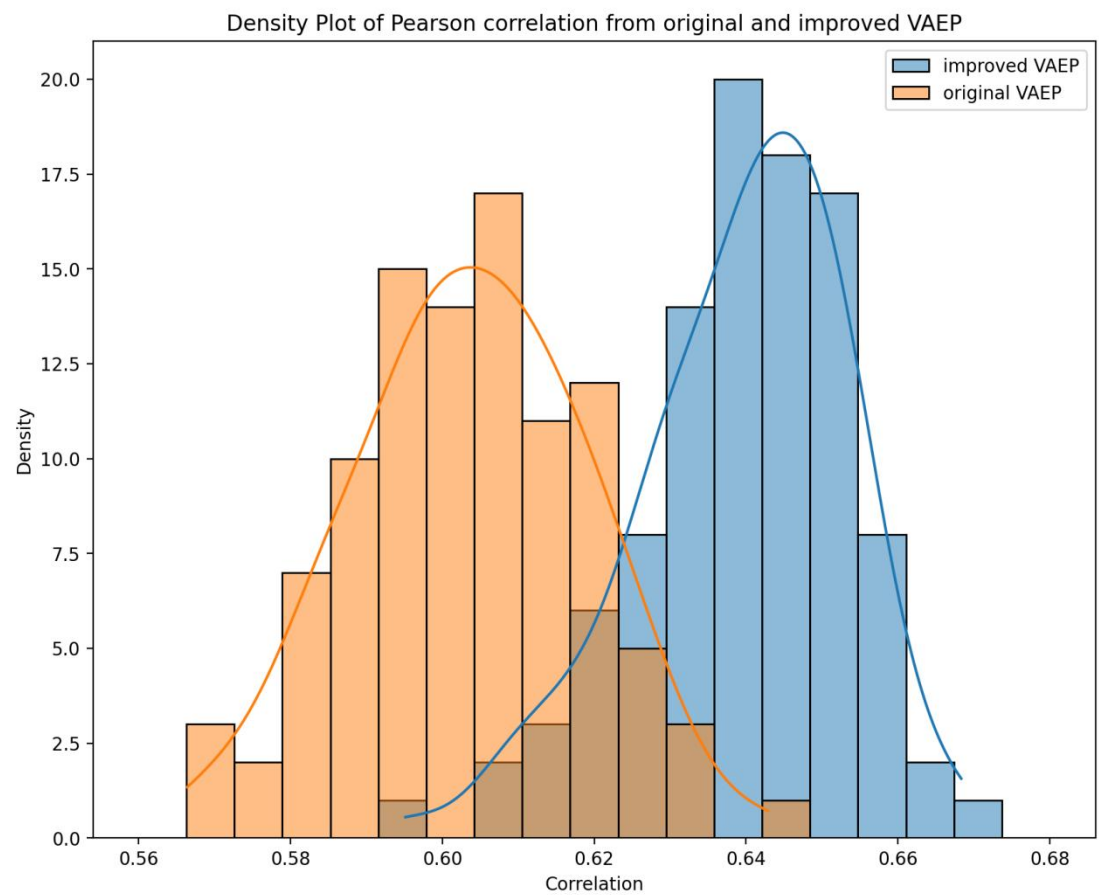


图 4.2（a）改进前后模型稳定性评估的 Pearson 相关系数对比图

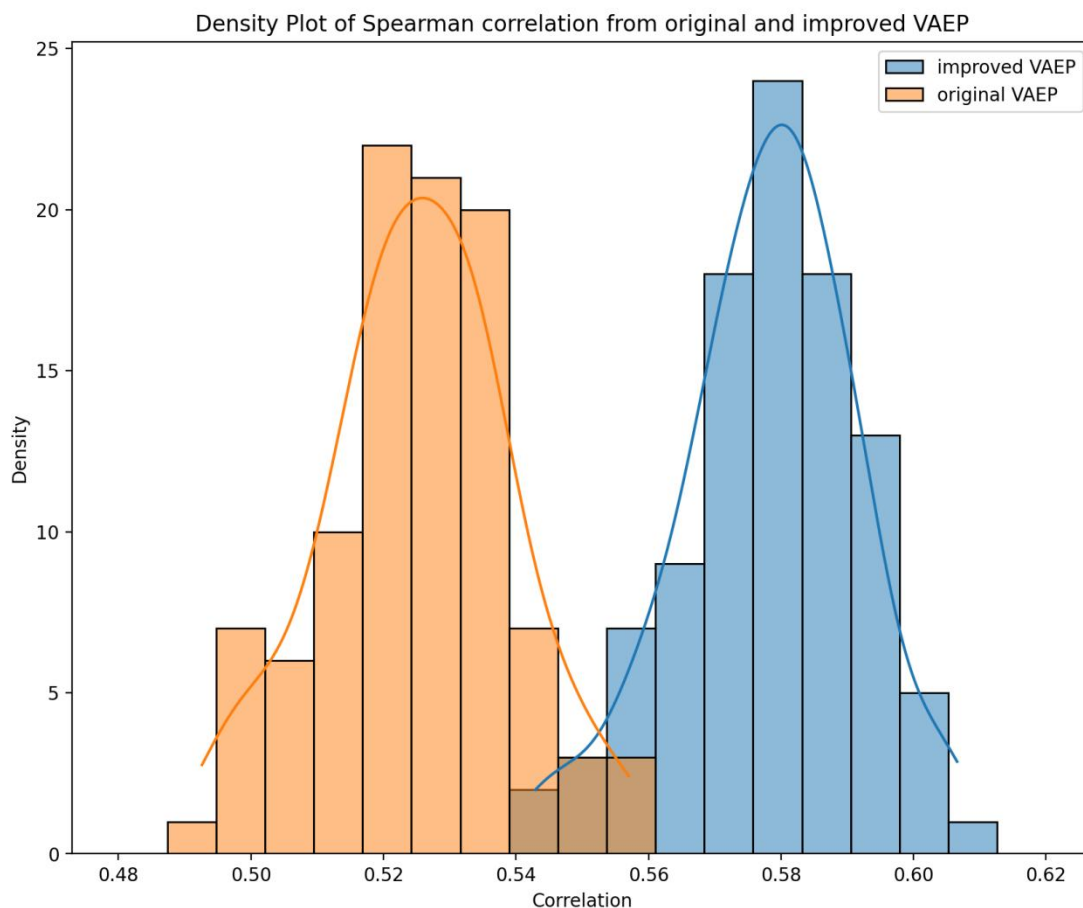


图 4.2 (b) 改进前后模型稳定性评估的 Spearman 相关系数对比图

4.3 模型解读

在这一部分，我们将探究模型中的各个特征对于预测结果的具体影响；并结合一些示例比赛事件，来展示模型对于球员动作价值的具体赋分方法。

4.3.1 变量重要性

我们将使用 Catboost 算法内置的 `feature_importances_` 函数来查看模型中每个特征的重要性指数，并将改进前后模型的对比如表 4.3 和表 4.4 中。

对于 P_{scores} 对应的模型，我们列举了重要性排名前七的特征。改进前后模型前七重要的特征完全一致，只是在具体排名内部出现了一些不同。动作 a_0 的类型、相对对手球门的距离和使用的身体部分列重要性的第一至三位，区别在于相比改进前模型，改进后模型倾向于使用更多关于动作 a_0 类型的信息。动作 a_0 的方向、移动的距离、动作 a_1 的类型、以及场上两队的进球差距这类比赛情境特征同样对于预测目前比赛状态下的进球概率有一定影响。

表 4.3 P_{scores} 模型改进前后变量重要性对比表

特征	改进后 P_{scores}	改进前 P_{scores}
actiontype_a0	0.492	0.344
dist_to_goal_a0	0.239	0.252
bodypart_a0	0.03	0.045
dx_a0	0.019	0.021
actiontype_a1	0.013	0.015
mov_d_a0	0.012	0.025
goalscore_diff	0.01	0.014

对于 P_{concedes} 对应的模型，我们同样列举了重要性排名前七的特征，但此时改进前后模型前七重要的特征并不完全一致。动作 a_0 的类型还是最重要的特征，且改进后模型依然相较改进前明显倾向于使用更多关于这一特征的信息。动作 a_1 的类型、所在位置的 x 轴坐标和动作 a_0 与 a_1 之间经过的时间同样有一定的作用。

表 4.4 P_{concedes} 模型改进前后变量重要性对比表

特征	改进后 P_{concedes}	改进前 P_{concedes}
actiontype_a0	0.504	0.282
actiontype_a1	0.069	0.041
x_a0	0.061	0.066
time_delta_1	0.044	0.035
angle_to_goal_a0	0.041	0.08
x_a1	0.027	/
mov_d_a0	0.019	/
dist_to_goal_a0	/	0.094
team_1	/	0.028

对比表 4.3 和表 4.4 可以发现， P_{scores} 对应的模型内的重要特征和 P_{concedes} 对应的模型内的重要特征有不少重合、但也有部分差异。两模型中动作 a_0 的类型都是最重要的因素，这很好理解：像进球、射门等重要的进攻动作肯定会提升进球概率；而犯规、出界等失误类型的动作也肯定会导致丢球概率的上升。在位置

方面的因素中， P_{scores} 模型更加倾向于使用动作相对对手球门距离的信息，但 P_{concedes} 模型更加倾向于使用动作所在位置的 x 轴坐标信息。这可能是因为，控制其他因素不变时，距离对手球门越近，进球概率显然就越高；但并不是距离对手的球门越远，丢球概率就越高，因为距离对手球门最远的地方是本方的角球区而非本方禁区——所以 P_{concedes} 模型采取的方法是基于位置的 x 轴坐标（ x 轴坐标越小，即越靠近本方底线，丢球概率就越高），并结合其他信息（如动作相对对手球门的角度）来预测丢球概率。

4.3.2 比赛案例分析

我们将使用一些 2015/2016 赛季五大联赛中的重要比赛作为案例，来展示我们的模型对于球员动作价值的具体赋分方法。

4.3.2.1 案例 1

2015 年 11 月 21 日，西甲第 12 轮上演国家德比，皇家马德里主场 0-4 惨败于巴塞罗那。我们首先选取苏亚雷斯在第 11 分钟首开纪录的进球进行分析。

这粒进球的发生过程如下。布斯克茨首先在中路将球交给罗贝托：在布斯克茨得球之前，模型拟合的巴塞罗那队的进球概率为 0.005，因为当时整体的比赛局势依然是巴塞罗那队在中路平稳地组织进攻，并未出现明显的机会；布斯克茨将球短传给罗贝托也只是常规的组织过程。但罗贝托接下来的起速对比赛局势有了一定改变，他接球后快速向前带球至皇家马德里队的禁区前沿，并向右送出了一脚直塞：这一推进过程瞬间撕开了皇家马德里的防线，从而模型对罗贝托的这一连串动作赋予了总计 0.052 的 VAEP 得分。最后，苏亚雷斯巧妙地捕捉到了皇家马德里队禁区里的空挡位置，接到了罗贝托的妙传，并完成了一次大力的脚尖捅射将球送入了皇家马德里队的球门：模型对他接球、射门以及进球三下动作分别赋予了 0.044、0.126 和 0.771 的 VAEP 得分。

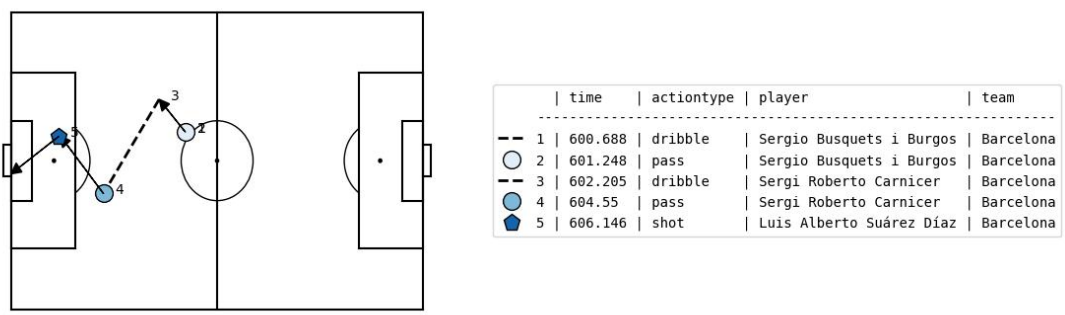


图 4.3 苏亚雷斯进球过程示意图

表 4.5 苏亚雷斯进球事件模型动作赋分表

球员	动作	P_{scores}	VAEP value
Sergio Busquets	receival + dribble + pass	0.007	0.002
Sergi Roberto	receival	0.007	0
Sergi Roberto	dribble	0.037	0.03
Sergi Roberto	pass	0.059	0.022
Luis Suárez	receival	0.103	0.044
Luis Suárez	shot	0.229	0.126
Luis Suárez	goal	1	0.771

我们分别针对罗贝托带球、传球以及苏亚雷斯射门、进球这四下动作对应的比赛状态应用机器学习的 SHAP 解释算法进行概率预测值的可视化解释。由于这次进球过程基本不涉及 P_{concedes} 模型, 所以这里只针对 P_{scores} 模型使用 SHAP 算法。

对于罗贝托带球这一动作对应的比赛状态, P_{scores} 模型预测了 0.037 的进球概率。罗贝托这一动作的方向向前、动作类型为带球、带球结束后相对对手球门的距离为 40.3 米、以及他向左前方带球突进的距离为 25.8 米, 这四项因素是使得 P_{scores} 模型提升了这一比赛状态的进球概率预测值的主要原因。




图 4.4 (a) 罗贝托带球动作 P_{scores} 预测值的 SHAP 算法解释图

对于罗贝托传球这一动作对应的比赛状态, P_{scores} 模型预测了 0.059 的进球概率。罗贝托传球结束后球相对对手球门的距离为 24.8 米、传球的方向向前、以及传球的距离为 17.2 米, 这三项因素是使得 P_{scores} 模型提升了这一比赛状态的进球概率预测值的主要原因。




图 4.4 (b) 罗贝托传球动作 P_{scores} 预测值的 SHAP 算法解释图

对于苏亚雷斯射门这一动作对应的比赛状态, P_{scores} 模型预测了 0.229 的进球概率; 这一数字与这次射门 0.259 的预期进球差异不大, 也体现出了在这一案例中模型对改进后标签的学习能力不错。苏亚雷斯射门时相对对手球门的距离为 13.4 米、以及动作类型为射门, 这两项因素是使得 P_{scores} 模型大幅提升了这一比赛状态的进球概率预测值的主要原因。




图 4.4 (c) 苏亚雷斯射门动作 P_{scores} 预测值的 SHAP 算法解释图

而对于苏亚雷斯进球这一动作对应的比赛状态， P_{scores} 模型预测了接近于 1 的进球概率。当然，这几乎完全都是动作类型为进球的结果。




图 4.4 (d) 苏亚雷斯进球动作 P_{scores} 预测值的 SHAP 算法解释图

需要额外再做解释的一点在于，如之前已经在 Atomic SPADL 部分提到的那样，我们将每次射门动作拆分成了射门和进球（或出界等其他结果）这样两次动作。这或许一开始会让人感到费解，但我们的想法是：拆分之后的射门动作指的是球员经过跑位、调整从而能够完成射门这一行为，而进球（或出界等其他结果）衡量的是球员这脚射门的具体质量如何。只要形成了射门，我们就会对球员之前的跑位、调整等努力给予正向价值评分；而至于射门质量很高形成进球还是射门质量很差导致出界等结果，会在后一次动作中被相应地给予正向或负向价值评分。

4.3.2.2 案例 2

同样是在这场国家德比中，我们再选取一次穆尼尔在第 88 分钟错失良机的过程进行分析。巴塞罗那队门将布拉沃先是直接摘下了皇家马德里队的传中，随后快速长距离手抛球给到中场左路附近的内马尔发动反攻：他的这一系列动作被总计赋予了 0.042 的 VAEP 得分（但此时 P_{scores} 的预测值只有 0.023，是因为布拉沃的这一系列动作不仅提升了本队的进球概率，还降低了本队的丢球概率）。内马尔随后往前一路带球突进至对方禁区左侧并送出了一脚传中：他的这两下处理一共被赋予了 0.08 的 VAEP 得分。穆尼尔在点球点附近跟进到位，完成了一脚射门，但却出人意料地将球推偏出了右侧立柱：他完成射门这一下动作被赋予了 0.051 的 VAEP 得分，但最终射门偏出的结果则使得他又被扣除了 0.154 的 VAEP 得分；即穆尼尔总体因为浪费了这次机会被赋予了 -0.103 的 VAEP 得分。

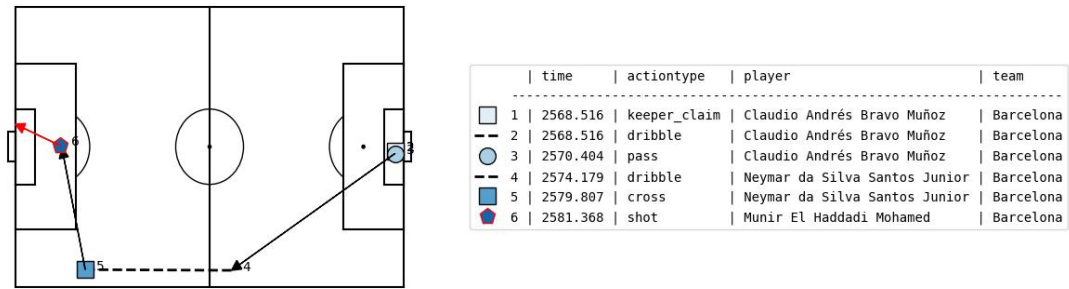


图 4.5 穆尼尔错失良机过程示意图

表 4.6 穆尼尔错失良机事件模型动作赋分表

球员	动作	P_{scores}	VAEP value
Claudio Bravo	keeper claim + dribble + pass	0.023	0.042
Neymar	receival + dribble	0.094	0.071

Neymar	cross	0.103	0.009
Munir El Haddadi	receival + shot	0.154	0.051
Munir El Haddadi	out	0	-0.154

4.3.2.3 案例 3

2015 年 9 月 22 日，德甲第 6 轮创造了当今世界足坛最难打破的记录之一。莱万多夫斯基在下半场替补登场后的九分钟之内打入五球，帮助拜仁慕尼黑主场 5-1 逆转沃尔夫斯堡。我们选取莱万多夫斯基在第 51 分钟扳平比分的进球进行分析。

这粒进球的发生过程如下。托马斯穆勒首先在中路将球分边给到格策：此时模型拟合的拜仁慕尼黑队的进球概率只有 0.01。格策随后将球快速扫传给到前插至禁区里的比达尔：他的这次传中被赋予了 0.077 的 VAEP 得分。接着比达尔将球后磕给了身后跟进的穆勒：他的这次动作被赋予了 -0.006 的 VAEP 得分。这一赋分可能显得有些不是非常合理，因为当时比达尔身前的空间已经被沃尔夫斯堡的防守队员所挤压，而后磕这一下则可以把球给到机会更好、无人贴身盯防的穆勒。但考虑到我们的模型是基于事件数据而非追踪数据进行拟合的，在赋分的过程中并不会考虑到场上无球队员的情况，所以比达尔的这次后磕在我们的模型中只会被视为一次“远离球门的回传”，并因此被赋予了负的 VAEP 得分。这也反映出了我们的模型依然具有着一定的局限性。

在穆勒接到了比达尔的后磕球之后，他向左前方趟了一步从而更靠近了点球点：他的这次动作被赋予了 0.081 的 VAEP 得分。此时沃尔夫斯堡的防守球员丹特做出了一个大胆的举动，他选择在禁区里从穆勒的斜后方进行铲球抢断，并且也干净地将球从穆勒脚下铲走：他的这次动作被赋予了 0.127 的 VAEP 得分，因为本来穆勒已经可以起脚射门了，他的这一次铲抢使得穆勒射门得分的几率大大下降。但不幸的是，在这一系列混乱之后，莱万多夫斯基还是正好跑到了球所在的位置，并在小禁区线上完成了推射进球：模型对他捕捉机会、射门进球这一整体动作赋予了 0.964 的 VAEP 得分。

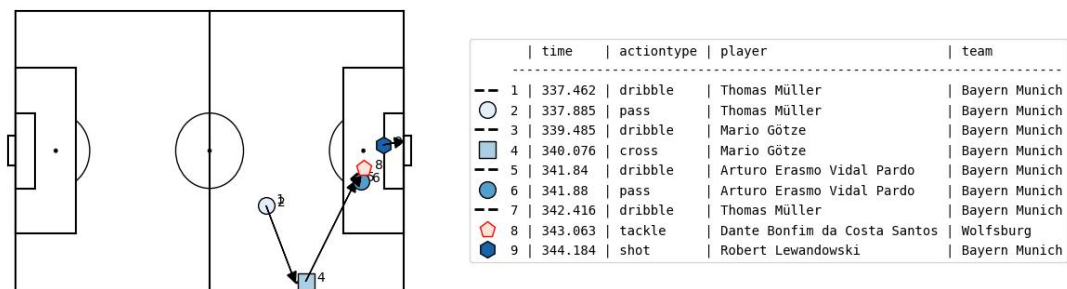


图 4.6 莱万多夫斯基进球过程示意图

表 4.7 莱万多夫斯基进球事件模型动作赋分表

球员	动作	P _{scores}	VAEP value
Mario Götze	receival + dribble + cross	0.087	0.077
Arturo Vidal	receival + dribble + pass	0.081	-0.006
Thomas Müller	dribble	0.162	0.081
Dante	tackle	0.036	0.127
Robert Lewandowski	shot	0.612	0.576
Robert Lewandowski	goal	1	0.388

5 应用分析

5.1 球员整体 VAEP 得分排名分析

我们将尝试应用我们的模型，去分析足球业界中的实际问题。首先，我们希望得出球员整体 VAEP 得分排名。考虑到门将位置的特殊性，本文暂时只将外场球员纳入分析的范围中。同时，为了保证我们通过 VAEP 得分衡量球员整体贡献的结果是连续稳定的，我们将只针对在 2015/2016 赛季五大联赛中的总出场时间达到 900 分钟（即踢满 10 场比赛）的球员进行分析。

5.1.1 西甲联赛球员排名分析

我们首先对 2015/2016 赛季西甲联赛每 90 分钟整体 VAEP 得分排名前十的球员进行分析。

意料之中的，梅西在这一榜单上又名列首位，他当然也是这一赛季巴塞罗那队卫冕西甲冠军的最大功臣。皇家马德里队的贝尔和本泽马分列二三位，他们两位球员的出场时间虽然不多（大约只有榜单内其他球员上场时间的三分之二），但依然能在有限的时间内分别贡献了 19 球 10 助和 24 球 7 助的高光数据，反映出他们在场上单位时间内的贡献更高。榜单中大部分的名字都耳熟能详，唯一也许有些出人意料的名字是皇家社会队的前锋阿吉雷切：这一赛季，他在 1207 分钟的上场时间中贡献了 13 粒进球，平均 90 分钟出头就可以打进一粒进球的效率绝对可以称得上是非常高效；况且他是在中游球队皇家社会打出的这一数据，更是体现出他作为一名优秀前锋的价值，从而他在我们的榜单上排名前五也完全合理。

表 5.1 2015/2016 赛季西甲联赛球员整体 VAEP 得分排名表

球员	上场总时间	VAEP_per_90	VAEP_total
Lionel Messi	2818	1.2753	39.9317
Gareth Bale	1784	1.2619	25.0133
Karim Benzema	2023	1.2467	28.0239
Luis Suárez	3257	1.1761	42.5626
Imanol Agirretxe	1207	1.0122	13.5752
Neymar	3148	0.9733	34.0427
Cristiano Ronaldo	3295	0.9515	34.8371
Ángel Correa	1017	0.8338	9.4225

Kévin Gameiro	2163	0.7943	19.0897
Antoine Griezmann	3134	0.7928	27.6072

5.1.2 英超联赛球员排名分析

我们继续对 2015/2016 赛季英超联赛每 90 分钟整体 VAEP 得分排名前十的球员进行分析。

在这一赛季中，莱斯特城上演了蓝狐奇迹；打入 25 球的凯恩则是力压打入 24 球的瓦尔迪和阿圭罗获得英超金靴。但考虑到阿圭罗的上场时间更少，他的进球效率更高，于是模型将阿圭罗放在了榜单的首位。而在 1000 分钟出头的上场时间内高效地打入了 8 粒进球的斯图里奇被放在了第二的位置。

在这张榜单中，除了一众我们熟悉的明星射手和高产边锋之外，有些球员在普通的进球或助攻榜单上排名并不靠前。库蒂尼奥在这个赛季的数据只有 8 球 5 助，这使得他在进球或助攻榜单上都是 20 名开外的水平。但他对于球队在进攻串联方面的贡献却不是用进球或助攻数据就能说明的，他在 2016 年获得了英超球迷协会评选的最佳球员奖也是体现出了他的价值。

表 5.2 2015/2016 赛季英超联赛球员整体 VAEP 得分排名表

球员	上场总时间	VAEP_per_90	VAEP_total
Sergio Agüero	2462	0.9724	26.6009
Daniel Sturridge	1038	0.8332	9.6101
Harry Kane	3536	0.7773	30.5402
Alexis Sánchez	2554	0.7616	21.6128
Jamie Vardy	3314	0.7061	25.9996
Philippe Coutinho	2097	0.7059	16.4476
Olivier Giroud	2577	0.6932	19.8498
Riyad Mahrez	3148	0.6919	24.2002
Dele Alli	2567	0.6386	18.2141
Romelu Lukaku	3366	0.6331	23.6767

5.1.3 球员动作数量-质量关系分析

对于一个 VAEP 得分很高的球员来说，其实他有两种方法做到这一点：一种是他进行动作的次数不多，但每次动作的价值很高；另一种是他平均每次动作的

价值一般，但他进行动作的次数很多。我们所理想化希望的：某一球员不仅进行动作的数量多、且每次动作的价值也很高，这实际在足球比赛中很难做到，大部分球员只能在两者间寻求一个平衡。由此，在这一部分，我们试图从球员每个动作产生的价值和他每 90 分钟内做出的动作数量这两个维度进行分析。

我们做出所有球员横轴为平均每个动作产生的价值、纵轴为每 90 分钟做出的动作数量的散点图，如图 5.1 所示。可以看出，大部分球员都分布在灰色反比例曲线所划分的左侧区域里，其中某些球员相对动作数量更多一点，某些球员相对动作质量更高一点。而在灰色反比例曲线所划分的右侧区域里，是我们得到的五大联赛所有球员 VAEP 得分中排名前 30 的球员。其中，更加位于图中右下侧的球员大都是纯粹的中锋（如苏亚雷斯、本泽马、莱万多夫斯基、奥巴梅扬等），在他们进行的动作中很多都是射门或进球：这些动作相对数量较少，但每次成功的此类动作都会被赋予很高的价值得分，因而也就反映为这些球员的动作数量较少，但平均动作价值较高。而更加位于图中左上侧的球员更多是一支球队的进攻组织或推进核心（如梅西、内马尔之于巴塞罗那，哈梅斯·罗德里格斯之于皇家马德里，迪马利亚之于巴黎圣日尔曼、以及桑切斯之于阿森纳等），他们在前场的位置更加灵活，持球的次数也更多；除了自己射门得分或直接助攻外，他们还需要承担大量的撕扯空间、突破、转移球等任务，而这些任务被赋予的价值得分相对直接射门进球来说就没有那么高，因而也就反映为这些球员的平均动作价值没有那么高（但依然高过大部分球员），但他们的动作数量很多。

值得一提的是，从图 5.1 中可以看出，梅西和伊布拉希莫维奇是 2015/2016 赛季五大联赛所有球员中每 90 分钟整体 VAEP 得分最高的两位球员。他们之间的区别正是在于，如上文所述，在约 2800 分钟的出场时间内完成了 26 球 16 助的梅西在巴塞罗那队的角色更加偏重于进攻核心，而在约 2500 分钟的上场时间内就交出了 38 球 13 助的亮眼数据的伊布拉希莫维奇则更加接近于一名纯粹的中锋。




图 5.1 球员动作数量-质量关系散点图

5.2 球员区分动作类型 VAEP 得分排名分析

每个球员在不同方面的能力都各有不同，如中锋普遍擅长射门、边锋大多擅长突破等。在这一部分，我们将区分球员在不同动作类型上的每 90 分钟 VAEP 得分，来对不同动作类型上对其最擅长的球员进行分析。

首先是进球动作。显然，在进球动作上排名靠前的球员肯定是完成射门动作质量极高、单位时间内进球非常多的队员。在进球动作每 90 分钟 VAEP 得分榜单上排名前五的球员分别是伊布拉希莫维奇、伊瓜因、贝尔、苏亚雷斯和本泽马，他们在这一赛季每 90 分钟的平均进球数是 1.35、1.06、0.96、1.11 和 1.07。基于我们改进后的 VAEP 框架，球员在进球动作上的得分可以近似理解为 $1 - xG$ ，即进球这一结果（1）相对预期进球（ xG ）的增加值，这也是我们着重进行模型校准的方面。因此，进球动作 VAEP 得分榜单上的排名与传统的每 90 分钟进球数的排名不一致是一个正常的现象，而这也侧面反映出了关于球员进球对应的射门机会质量的结论：贝尔和伊瓜因最终形成进球的射门机会相对苏亚雷斯和本泽马来说普遍没有那么好，但他们将其转化为进球的能力更强。

表 5.3 进球单项动作 VAEP 得分排名表

球员	goal VAEP per 90
Zlatan Ibrahimović	0.8931

Gonzalo Higuaín	0.7787
Gareth Bale	0.7608
Luis Suárez	0.7390
Karim Benzema	0.7111
Robert Lewandowski	0.6676
Imanol Agirretxe	0.6495
Cristiano Ronaldo	0.6480
Sergio Agüero	0.6095
Lionel Messi	0.5964

其次是传球动作。在传球动作上排名靠前的球员不只是具有很高的传球准确度，他们的传球同时也要对球队的攻防两端能起到显著的贡献。在传球动作每 90 分钟 VAEP 得分榜单上，梅西当之无愧地排名榜首，在他身后有像帕斯托雷、法布雷加斯、卡索拉和伊涅斯塔等一众中场大师。可能有些出人意料的，是德国的两大中后卫博阿滕和胡梅尔斯也出现在了这张榜单中。但其实，博阿滕从出道以来就不是一个传统的中后卫，而是一名具备强大传球能力的“出球型中卫”，从后场发动精准的长传进攻一向是他的特长（最著名的例子莫过于 2012/2013 赛季欧洲冠军联赛决赛，里贝里助攻罗本的绝杀正是基于博阿滕在后场发起的长传）；而胡梅尔斯同样出球能力出色，长传精准，也擅长在由守转攻的过程中送出关键球，很多时候是多特蒙德队进攻的第一发起者。他们能够出现在这张榜单中，也反映出他们在那个赛季的联赛中组织进攻方面的贡献。

表 5.4 传球单项动作 VAEP 得分排名表

球员	pass_VAEP_per_90
Lionel Messi	0.1278
Javier Pastore	0.1191
Jérôme Boateng	0.1002
Cesc Fàbregas	0.0999
Santi Cazorla	0.0960
Andrés Iniesta	0.0953
Duda	0.0924
Jorginho	0.0909
Mats Hummels	0.0879
Francesco Lodi	0.0878

最后是盘带动作。在盘带动作每 90 分钟 VAEP 得分榜单上，内马尔和梅西两人以显著优势位列前二。排名第三的是法甲里尔队的鲍法尔，这位球员的名气尽管在这张榜单中略显逊色，但其实他的盘带以及过人能力一直是五大联赛的一流水平。在这一赛季的法甲联赛中，他获得了过人王的荣誉，也以 125 次成功盘带位列总盘带榜单的第二，且他每 90 分钟的成功盘带次数与排名第一的本·阿尔法几乎相同。但他踢球方式独、身体对抗差、配合能力不佳的缺点也是极为显著，这制约了他的向上发展。总的来说，在盘带动作榜单上，主要是梅西、帕斯托雷和本·阿尔法这类型的前腰，以及内马尔、萨内和道格拉斯·科斯塔这类型的边锋，他们都需要通过精细的盘球能力来体现出自己的价值。

表 5.5 盘带单项动作 VAEP 得分排名表

球员	dribble VAEP_per_90
Neymar	0.3063
Lionel Messi	0.2821
Sofiane Boufal	0.2449
Keita Baldé	0.2434
Dries Mertens	0.2380
Leroy Sané	0.2320
Javier Pastore	0.2198
Hatem Ben Arfa	0.2186
Douglas Costa	0.2164
Paul - Georges Ntep	0.2163

5.3 球员比赛风格对比分析

在这一部分，我们将应用改进后模型计算得出的区分动作类型 VAEP 得分，来对比分析不同球员之间比赛风格和能力的差异，并尝试由此对球队的引援提出模型角度的建议。

5.3.1 寻找最类似梅西的球员

梅西，是过去很长一段时间里世界上最好的球员。而大家经常会问的一个问题是：那么谁是最类似梅西的那一个？对此，我们试图从数据的角度量化地回答这一问题。

我们考虑将每个球员的每 90 分钟区分动作类型 VAEP 得分，就作为该球员

的特征向量，并通过计算球员特征向量之间的距离，来得出有关两位球员之间类似与否的结论。^[13]由于某些动作类型的平均 VAEP 得分显著地高于其他动作（如进球、射门等），为了防止距离计算完全被这些动作类型所主导，我们将先对球员的特征向量进行标准化，再进行距离的计算。

根据以上方法我们计算了所有球员和梅西之间的距离，距离由近到远排名前六位的球员分别是：帕斯托雷、迪马利亚、伊布拉希莫维奇、博格巴、罗本和库蒂尼奥。接下来，我们将细致地对比分析以上一共七位球员的能力和比赛风格。

我们选取了进球、传球、传中和盘带这四项对于前场球员来说至关重要的细分动作，来对这七位球员进行对比分析。从图 5.2 中可以看出，在进球方面，伊布拉希莫维奇最高，梅西其次，而其他球员的这项能力得分相对都不是很高。在这些球员中，只有伊布拉希莫维奇是典型的中锋，所以他在进球方面的得分遥遥领先也是理所应当的；而其他球员更多承担的是前腰核心或边锋突破手的角色，进球并不是他们的主要任务，梅西在这一方面领先于他同类型的其他球员，而迪马利亚和库蒂尼奥相对更加接近梅西。

在传球方面，梅西的得分排名第一，帕斯托雷和迪马利亚次之。而在传中方面，梅西的得分较低，迪马利亚和罗本的得分相对更高，这是因为他们两人的踢法偏向于纯粹的边锋，而梅西的角色兼具前腰、边锋和前锋。在盘带方面，梅西的得分又是排名第一，帕斯托雷和罗本与其较为接近，且大家总体在盘带动作上得分的差异不大。

总的来说，如果不考虑进球情况的话，我们可以认为帕斯托雷在其他方面是较为接近梅西的球员。但综合以上四点来看的话，迪马利亚或许才是梅西最好的平替：他在进球、传球和盘带这三方面相比梅西的差距相对不大，且他在传中方面有着更大的优势。当然，这也体现出他偏向于边锋的比赛风格，而这和在前场十分全面的梅西有着显著的差异。




图 5.2 梅西及类似梅西的球员区分动作类型 VAEP 得分图

5.3.2 拜仁慕尼黑中后卫对比分析

2015/2016 赛季德甲联赛结束之后，拜仁慕尼黑对球队中后卫位置上的配置进行了变动，在保留了博阿滕和哈维·马丁内斯两位功勋球员的同时，引入了多特蒙德队的主力胡梅尔斯，并将贝纳蒂亚外租给了尤文图斯。在这一部分，我们尝试使用我们的模型来理解这一转会操作，并对拜仁慕尼黑队内的这前后四位中后卫进行比赛风格和能力上的对比分析。

我们选取了进球、传球、盘带、解围、拦截和抢断这六项细分动作，来对以上四位中后卫进行对比分析。从图 5.3 中可以看出，在进球方面，博阿滕相对较弱，而其他三位中后卫都有一定的进球能力。在传球和盘带方面，博阿滕和胡梅尔斯的得分明显高于哈维·马丁内斯和贝纳蒂亚，这也反映出他们两人是我们上文提到的“现代化出球型中卫”，可以作为球队推进的第一发起者，发动长传进攻或带球深入对方阵线。而在解围、拦截和抢断这三项防守动作方面，胡梅尔斯总的来说是表现最好的那一个，尽管他在解围方面的得分不佳，这可能反映出他解围失误和盲目性的问题；博阿滕尽管在另外两项防守数据上的表现一般，但在解围方面却显现出一定的优势；哈维·马丁内斯和贝纳蒂亚的表现则较为类似，都属于各项均不突出但也可以接受的类型。

回到拜仁慕尼黑中卫线搭建的问题上，基于我们改进后模型计算所得的数据，我们可以认为，引进胡梅尔斯是增强后卫线实力的一个合理选择：由此形成的主力中后卫组合（胡梅尔斯搭档博阿滕）拥有着强大的发动进攻的能力，更加符合

现代化足球的要求；同时胡梅尔斯在防守端的综合能力也略微优于他的两位前任，尽管在进球方面有一定差距，但也并不大。而对于整体风格比较相似、但在盘带和出球方面不占优势的贝纳蒂亚和哈维·马丁内斯来说，由于后者同时也能踢后腰的位置，贝纳蒂亚就成为了可以离队的那一个。因此总的来说，拜仁慕尼黑的这一转会操作在量化数据上是可以得到有力支持的。




图 5.3 拜仁慕尼黑中后卫区分动作类型 VAEP 得分图

5.3.3 寻找拉姆的替代者

对于拜仁慕尼黑来说，除了中后卫位置上的补强之外，右边后卫的补强也是那一时期需要考虑的一个大问题。在 2017 年初，右边后卫位置上原来的主力，世界级球员、作为队长率领德国队捧起大力神杯的传奇拉姆激流勇退。在后来的几个赛季中，拜仁先后尝试过拉菲尼亚、基米希、帕瓦尔等球员作为该位置的主力，但他们在这个位置上始终都无法长期令人满意。我们试图回到拉姆宣布退役的那个时间点，尝试基于 2015/2016 赛季的数据来为拜仁慕尼黑寻找他的替代者。

我们首先还是用上文提到的方法计算了所有在这一赛季联赛中有过右边后卫出场经历的球员和拉姆之间的距离，并选出距离最近的十位球员；然后结合球员的年龄（小于拉姆）和出场时间（至少 1500 分钟）考虑，筛选出以下五位备选：拜仁慕尼黑自己队内的拉菲尼亚、巴塞罗那的罗贝托、那不勒斯的希萨伊、利物浦的克莱因、以及伯恩茅斯的亚当·史密斯。

接下来，我们将细致地对比分析以上五位球员加上拉姆本人一共六位球员的

能力和比赛风格，从而希望能够基于数据对于寻找拉姆的替代者提出建议。我们选取了传球、传中、盘带、解围、拦截和抢断这六项细分动作来对这六位球员进行对比分析。从图 5.4 中可以看出，如果单论防守的三项指标，拉姆相比其他球员并无太大的优势，甚至整体都不及队友拉菲尼亚。但拉姆最大的优势在于盘带能力，他在盘带动作上的得分遥遥领先于其他所有对比的球员；同时，他在传中方面的得分也相对不错。基于此，我们考虑克莱因和亚当·史密斯作为拉姆替代者的合适人选：尽管他们两人分别在解围和抢断上呈现出较大的短板，但他们在其他两项防守数据上都表现得不错；更重要的是，他们在盘带和传中方面的能力更为接近拉姆，其中克莱因的传中能力略微好于亚当·史密斯，而后的者的盘带能力略好于前者。当然，这一建议也只是假设性的，无法验证两位球员如果真的加盟拜仁慕尼黑是否会有更好的表现。事实上，他们二人后来职业生涯的发展也都称不上成功：克莱因在连续两个赛季稳坐利物浦主力右边后卫的位置后，由于连续的背部伤病和十字韧带撕裂，状态下滑明显，在离开利物浦后最终是在水晶宫才重新获得了稳定的主力位置；而亚当·史密斯则只是一直坚守在伯恩茅斯至今。




图 5.4 拉姆及拉姆的潜在替代者区分动作类型 VAEP 得分图

6 总结与展望

本文围绕足球球员动作价值评估这一主题展开，构建了基于事件数据的研究框架，根据这一框架使用数据拟合了模型，并尝试对拟合的模型进行实际应用。

在构建研究框架层面，本文引入了 Atomic SPADL 这种标准化的球员动作表示方式，并结合 VAEP 框架，将球员动作价值评估转化为进球和丢球概率变化的量化估计；然后针对这两个概率估计问题，参考了基于 Atomic SPADL 的三大特征体系构建方法，并重点改进了标签的构建方式，将射门动作对应的预期进球值（xG）纳入标签考量，以期能为模型训练提供更合理的数据支撑。

在实证分析的过程中，本文使用了 Statsbomb 公开提供的 2015/2016 赛季五大联赛全部的事件数据，通过描述性统计，揭示了不同联赛中比赛风格的差异、各动作类型的分布情况、以及射门与进球的时间规律和相关影响因素。在模型拟合部分，具体采用了 Catboost 算法，通过网格搜索交叉验证确定了最优的超参数选择；在模型评估部分，从标准化 Brier score、模型校准和模型稳定性三方面说明了改进后模型相对原模型的优势和有效性；而在模型解读部分，则主要是使用了 SHAP 算法，并结合实际比赛案例来展示模型对球员动作的赋分逻辑。

最后，在实际应用的层面上，本文基于改进后模型计算得出的球员总体和区分动作类型 VAEP 得分，分别进行了总体和区分动作类型的球员贡献排名分析；同时，也通过使用区分动作类型的 VAEP 得分，对不同球员之间比赛风格和能力的差异进行了对比分析，并基于此尝试对球队的引援提供模型角度的建议。

但本文也存在着以下的不足。首先，由于数据公开的问题，本研究暂时无法获取到相关的追踪数据，所有的模型构建和分析都只是基于事件数据进行的；未来如果能够获取到相关的追踪数据，则可以考虑使用追踪数据构建更多反映更加全面的比赛状态的特征，从而提高模型对于比赛过程的理解能力。其次，我们在构建模型框架的过程中直接使用了经验的超参数，并只尝试了 Catboost 算法来拟合模型；未来可以考虑尝试不同超参数和机器学习算法的选取，以期获得更好的模型表现和解释度。

最后，在基于我们拟合的模型得出的球员整体 VAEP 得分排名中，位居前列的基本都是前锋。这反映出，我们的模型天然对于进攻队员有偏好，而对于防守球员则相对低估。对此，我们的理解是，对于进攻过程，我们可以把主要的贡献都分配到过程中有球的队员上；但防守过程并不是简单的由某一位球员完成的，因为持球队员是对方的进攻球员，防守需要的更多是整个团队无球的组织，很多时候并不需要实际做出一次会被记录下的动作（如解围、拦截、抢断等）就可以完成一次高质量的防守，但这类贡献在我们的模型中无法被呈现出来，模型也很难客观地对这类贡献进行分配。这个问题需要进一步的深入研究和分析。

7 附录

7.1 (non-Atomic) SPADL 包含的所有动作类型列举

动作类型	具体介绍
Pass	比赛进行中的普通传球
Cross	传中至禁区内
Throw-in	掷界外球
Crossed corner	角球传中至禁区内
Short corner	短角球
Crossed free-kick	任意球传中至禁区内
Short free-kick	短任意球
Take on	尝试盘带过掉对手
Foul	犯规
Tackle	对球进行抢断
Interception	拦截球
Shot	非点球或任意球的射门尝试
Penalty shot	点球射门
Free-kick shot	直接任意球射门
Keeper save	守门员扑出射向球门的球
Keeper claim	守门员接住传中球
Keeper punch	守门员将球击出
Keeper pick-up	守门员捡起球
Clearance	球员解围
Bad touch	球员触球失误并丢球球权
Dribble	球员带球至少 3 米
Goal kick	开门球

7.2 Atomic SPADL 新增的动作类型列举

动作类型	具体介绍
Receival	接球
Interception	拦截对方球队的传球
Out	球出界
Off-side	接球球员越位

Goal	进球
Own goal	乌龙球
Yellow card	黄牌
Red card	红牌

8 参考文献

- [1] Tuyls K, Omidshafiei S, Muller P, et al. Game Plan: What AI can do for Football, and What Football can do for AI[J]. Journal of Artificial Intelligence Research, 2021, 71: 41-88.
- [2] Barnett V, Hilditch S. The effect of an artificial pitch surface on home team performance in football (soccer)[J]. Journal of the Royal Statistical Society Series A: Statistics in Society, 1993, 156(1): 39-50.
- [3] Ensum J, Pollard R, Taylor S. Applications of logistic regression to shots at goal in association football: Calculation of shot probabilities, quantification of factors and player/team[J]. Journal of Sports Sciences, 2004, 22(6): 500-20.
- [4] IJtsma, S. 2015. A Close Look at My New Expected Goals Model. 11tegen11.
- [5] Worville, T. 2017. Expected assists in context. Stats Perform.
- [6] Decroos T, Bransen L, Van Haaren J, et al. Actions speak louder than goals: Valuing player actions in soccer[C]//Proceedings of the 25th ACM SIGKDD international conference on knowledge discovery & data mining. 2019: 1851-1861.
- [7] Singh, K. 2019. Introducing expected threat. karun1710.
- [8] Decroos T, Davis J. Valuing on-the-ball actions in soccer: a critical comparison of XT and VAEP[C]//Proceedings of the AAAI-20 Workshop on Artificial Intelligence in Team Sports. AI in Team Sports Organising Committee, 2020: 1-8.
- [9] Robberechts P. Valuing the art of pressing[C]//Proceedings of the StatsBomb Innovation In Football Conference. StatsBomb, 2019: 1-11.
- [10] Decroos T, Davis J. Interpretable prediction of goals in soccer[C]//Proceedings of the AAAI-20 workshop on artificial intelligence in team sports. 2019.
- [11] Prokhorenkova L, Gusev G, Vorobev A, et al. CatBoost: unbiased boosting with categorical features[J]. Advances in neural information processing systems, 2018, 31.
- [12] Davis J, Bransen L, Devos L, et al. Methodology and evaluation in sports analytics: challenges, approaches, and lessons learned[J]. Machine Learning, 2024, 113(9): 6977-7010.
- [13] Decroos T, Davis J. Player vectors: Characterizing soccer players' playing style from match event streams[C]//Joint European conference on machine learning and knowledge discovery in databases. Cham: Springer International Publishing, 2019: 569-584.
- [14] Bransen L, Van Haaren J. Measuring football players' on-the-ball contributions from passes during games[C]//Machine Learning and Data Mining for Sports

Analytics: 5th International Workshop, MLSA 2018, Co-located with ECML/PKDD 2018, Dublin, Ireland, September 10, 2018, Proceedings 5. Springer International Publishing, 2019: 3-15.

[15]Bransen L, Van Haaren J, van de Velden M. Measuring soccer players' contributions to chance creation by valuing their passes[J]. Journal of Quantitative Analysis in Sports, 2019, 15(2): 97-116.

[16]Fernández J, Bornn L, Cervone D. Decomposing the immeasurable sport: A deep learning expected possession value framework for soccer[C]//13th MIT Sloan Sports Analytics Conference. 2019, 2.

[17]Handbook of statistical methods and analyses in sports[M]. Crc Press, 2017.

[18]Decroos T. Soccer analytics meets artificial intelligence: Learning value and style from soccer event stream data[J]. 2020.

[19]Pappalardo L, Cintia P, Ferragina P, et al. PlayeRank: data-driven performance evaluation and player ranking in soccer via a machine learning approach[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2019, 10(5): 1-27.

[20]Decroos T, Van Haaren J, Dzyuba V, et al. STARSS: a spatio-temporal action rating system for soccer[C]//Machine Learning and Data Mining for Sports Analytics ECML/PKDD 2017 workshop. Springer, 2017, 1971: 11-20.